18. Регрессионный анализ. Несмещенность, состоятельность и эффективность оценки коэффициентов регрессии. Оценка остаточной дисперсии. Закон распределения коэффициентов регрессии. Закон распределения остаточной суммы квадратов.
19. Статистический анализ коэффициентов регрессии: проверка значимости коэффициентов, проверка простейших линейных гипотез. Проверка значимости всей регрессии, сравнение двух уравнений регрессии. Коэффициент детерминации.
20. Проверка адекватности модели. Кросс-проверка. Проверка основных предположений регрессионного анализа. Доверительный интервал для прогноза. Методы регуляризации.

Список литературы

1. *Ивченко Г. И. Медведев Ю. И.* Введение в математическую статистику. — Москва : ЛКИ, 2010, 2014, 2015.
2. *Лагутин М. Б.* Наглядная математическая статистика. — 9-е изд. — Москва : Лаборатория знаний, 2023.
3. *Чернова Н. И.* Математическая статистика. Учебное пособие. — Новосибирск, 2014. https://tvims.nsu.ru/chernova/ms/ms_nsu14.pdf
4. *Боровков А. А.* Математическая статистика. — 3-е изд. — Москва : Физматлит, 2007.
5. *Кобзарь А. И.* Прикладная математическая статистика: для инженеров и научных работников. — 2-е изд., испр. — Москва : Физматлит, 2012.

ПЕРВОЕ ЗАДАНИЕ

(срок сдачи 13–18 апреля)

1. Случайная величина распределена равномерно на отрезке $[0,\,\theta]$. По выборке объема n найдены оценки параметра θ : $\tilde{\theta_1} = 2\bar{x}$, $\tilde{\theta_2} = x_{\min}$, $\tilde{\theta_3} = x_{\max}$, $\tilde{\theta_5} = \left(x_1 + \dfrac{\sum\limits_{k=2}^{n} x_k}{(n-1)} \right)$.

a) Проверить оценки на несмещенность и состоятельность. Исправить эти оценки, если необходимо.

b) Какая из исправленных оценок более эффективна?

2. Случайная величина имеет экспоненциальный закон распределения

$$p(x) = \begin{cases} e^{-x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Сгенерируйте выборку объема $n = 25$.

a) Определить по выборке моду, медиану, размах, оценку коэффициента асимметрии.
b) Построить эмпирическую функцию распределения, гистограмму и boxplot.
c) Сравнить оценку плотности распределения среднего арифметического элементов выборки, полученную с помощью ЦПТ, с бутстраповской оценкой этой плотности.
d) Найти бутстраповскую оценку плотности распределения коэффициента асимметрии и оценить вероятность того, что коэффициент асимметрии будет меньше 1.
e) Сравнить плотность распределения медианы выборки с бутстраповской оценкой этой плотности.

3. Случайная величина имеет экспоненциальное распределение $p(x) = \begin{cases} e^{-x/\theta}/\theta, & x \geq 0, \\ 0, & x < 0, \end{cases} \theta > 0$. По выборке объема $n = 3$ найдены оценки параметра θ : $\tilde{\theta_1} = \bar{x}$, $\tilde{\theta_3} = x_{(2)}$ (второй член вариационного ряда).

a) Проверить оценки на несмещенность. Исправить эти оценки, если необходимо.
b) Какая из исправленных оценок более эффективна?
c) Исследовать эти оценки на эффективность с помощью неравенства Крамера–Рао.

4. Случайная величина с равной вероятностью принимает любое значение на интервале $(-1, 1)$, кроме 0, и принимает значения 0 и 2 с одинаковой вероятностью.

a) По выборке объема n найти оценки параметров случайной величины методом моментов и методом максимального правдоподобия.
b) Проверить оценки на несмещенность и состоятельность.
c) Исследовать эти оценки на эффективность с помощью неравенства Крамера–Рао.

5. Случайная величина распределена равномерно на отрезке $[\theta, 2\theta]$.

a) По выборке объема n найти оценки параметра θ методом моментов и методом максимального правдоподобия.
b) Проверить оценки на несмещенность и состоятельность. Исправить эти оценки, если необходимо.
c) Сравнить эффективность исправленных оценок.
d) Построить точный доверительный интервал для параметра θ.

e) Построить асимптотический доверительный интервал для параметра θ.

f) Сгенерируйте выборку объема $n = 100$ для некоторого значения параметра θ. Вычислите указанные выше доверительные интервалы для доверительной вероятности 0.95.

g) Численно постройте бутстраповский доверительный интервал.

h) Сравнить все интервалы.

6. Случайная величина имеет распределение Парето:

$$p(x) = \begin{cases} \dfrac{\theta - 1}{x^\theta}, & x \geq 1 \\ 0, & x < 1 \end{cases}, \quad \theta > 1.$$

a) По выборке объема n найти оценку параметра θ методом максимального правдоподобия.

b) Построить доверительный интервал для медианы.

c) Построить асимптотический доверительный интервал для параметра θ.

d) Сгенерируйте выборку объема $n = 100$ для некоторого значения параметра θ. Вычислите указанные выше доверительные интервалы для доверительной вероятности 0.95.

t) Численно постройте бутстраповский доверительный интервал двумя способами, используя параметрический бутстрап и непараметрический бутстрап.

f) Сравнить все интервалы.

7. Ниже приводятся ставшие классическими данные Борткевича о числе лиц, убитых ударом копыта в 10 прусских армейских корпусах за 20 лет (1875—1894).

i – число смертей в одном корпусе за год	0	1	2	3	4
число случаев, когда произошло i смертей	109	65	22	3	1

Проверить гипотезу о том, что число смертей в одном корпусе за год подчиняется распределению Пуассона.

8. Произведено измерение размеров деталей в двух партиях по 100 деталей в каждой партии. В первой партии оказалось 25 деталей с заниженным размером, 50 деталей с точным размером, 25 деталей с завышенным размером, а во второй партии аналогичные числа оказались равны 52, 41, 7 соответственно. Проверить гипотезу о независимости номера партии деталей и размера детали.

9. Участники олимпиады по математике разбиты на два потока по 300 человек в каждом. Итоги олимпиады оказались следующими: в первом

потоке оценки 2, 3, 4, 5 получили соответственно 33, 43, 80 и 144 человека, соответствующие данные для второго потока 39, 35, 72 и 154. Можно ли считать оба потока однородными?

10. При снятии показаний измерительного прибора десятые доли деления шкалы прибора оцениваются «на глаз» наблюдателем. Количества цифр 0, 1, 2, ..., 9, записанных наблюдателем в качестве десятых долей при 100 независимых измерениях, равны 5, 8, 6, 12, 14, 18, 11, 6, 13, 7 соответственно.

a) Проверить гипотезу о согласии данных с законом равномерного распределения с помощью критерия χ^2 и с помощью критерия Колмогорова. Сравнить результаты.

b) Проверить гипотезу о согласии данных с законом нормального распределения с помощью критерия χ^2 и с помощью критерия Колмогорова. Сравнить результаты.

11. Основная гипотеза H_0 состоит в том, что случайная величина имеет распределение с плотностью $p_0(x) = \begin{cases} 1, & x \in (0,\,1) \\ 0, & x \notin (0,\,1) \end{cases}$. Альтернатива H_1 состоит в том, что случайная величина имеет распределение с плотностью $p_1(x) = \begin{cases} \dfrac{e^{1-x}}{e-1}, & x \in (0,\,1) \\ 0, & x \notin (0,\,1) \end{cases}$.

a) Построить наиболее мощный критерий проверки этих гипотез по выборке объема $n = 1$ с уровнем значимости α, найти ошибки первого и второго рода, мощность критерия.

b) Построить наиболее мощный критерий проверки этих гипотез по выборке объема $n = 2$ с уровнем значимости α, найти ошибки первого и второго рода, мощность критерия.

c) Построить наиболее мощный асимптотический критерий проверки этих гипотез по выборке объема n с уровнем значимости α, найти ошибки первого и второго рода, мощность критерия, исследовать состоятельность этого критерия.

d) Построить оптимальный критерий по выборке объема n с критической областью $x_{\min} < c$ и уровнем значимости α, найти ошибки первого и второго рода, мощность критерия, исследовать состоятельность этого критерия.

12. У игрока, наблюдавшего за игрой в четырехгранные кости, создалось впечатление, что четверка выпадает в 8 случаях из 24, тройка в 4, а остальные две грани выпадают равновероятно. Получив приглашение

принять участие в игре, игрок попросил разрешения предварительно проверить свою гипотезу на двух производимых подряд бросаниях кости. Единственная рассматриваемая им альтернатива состоит в том, что игральная кость сделана «честно». Найти наиболее мощный критерий с уровнем значимости 0,2. Найти мощность критерия.

13. Исследование длины и ширины 139 черепов, найденных в Верхнем Египте и относимых к расе, жившей за 8000 лет до нашей эры, показало, что стандартное отклонение длины и ширины черепа 5,722 и 4,612 мм соответственно. Те же величины, выведенные на основании обследования 1000 европейцев, оказались равными 6,161 и 5,055 мм. Предполагая, что законы распределения длины и ширины черепа нормальные, выяснить, можно ли считать расхождение стандартов случайным. Построить график мощности критерия.

14. Пусть x_n и y_m — независимые случайные выборки из нормального распределения с параметрами $a, \sigma_x^2 = 2$ и $b, \sigma_y^2 = 1$ соответственно. Используя реализации случайных выборок: $x = \{-1.11, -6.10, 2.42\}$, $y = \{-2.29, -2.91\}$, проверить гипотезу о равенстве средних против альтернатив $a > b$. Построить график мощности критерия.

ВТОРОЕ ЗАДАНИЕ

(срок сдачи 11–16 мая)

1. Случайный вектор $(\xi_1, \xi_2, \xi_3, \xi_4, \xi_5, \eta)$ имеет компоненты, распределенные по следующему закону: $\xi_k \sim R(-1, 1)$, $\eta \sim N(2 + 3x_1 - 2x_2 + x_3 + {} + x_4 - x_5, 1.5^2)$, где x_k это значения, которые принимает случайная величина ξ_k. Сгенерировать выборку объема $n = 50$.

a) Проверить переменные ξ_k на мультиколлинеарность.

b) Определить уравнение линейной регрессии $\eta = \beta_0 + \sum_{k=1}^{5} \beta_k \xi_k$ и проверить значимость коэффициентов.

c) Определить коэффициент детерминации и проверить его значимость.

d) Найти значение в точке $x_k = 0$ и построить 95% доверительный интервал.

e) Проверить предположение о независимости ошибок измерения.

f) Проверить предположение о нормальности распределения ошибок.

g) Исследовать регрессию на выбросы.

h) Провести кросс-проверку регрессии.

i) Проверить адекватность регрессии, сделав 5 повторных измерений в одной точке.

j) Удалить переменную, соответствующую наименее значимому коэффициенту и повторить пункты b и c, сравнить уравнения регрессии.

k) Сравнить уравнения регрессии бутстрапом.

2. В таблице приведены данные о содержании иммуноглобулина $Ig\ A$ в сыворотке крови у больных пяти возрастных групп:

№	Содержание $Ig\ A(\%)$
1	83, 85
2	84, 85, 85, 86, 86, 87
3	86, 87, 87, 87, 88, 88, 88, 88, 88, 89, 90
4	89, 90, 90, 91
5	90, 92

a) Определить влияние возраста на содержание иммуноглобулина в крови с помощью регрессионного анализа.

b) Провести попарное сравнение средних в рамках регрессионной модели, с учетом множественности проверяемых гипотез.

3. По трем значениям случайного вектора $(\xi, \eta, \omega) : (1, 0, 1), (0, 1, 5)$ и $(1, 1, 2)$:

a) найти уравнение линейной регрессии $\omega = a\xi + b\eta$;

b) найти уравнение *ridge* регрессии $\omega = a\xi + b\eta$, построить график $CVSS$ и определить значение параметра регуляризации;

c) найти уравнение *lasso* регрессии $\omega = a\xi + b\eta$, построить график $CVSS$ и определить значение параметра регуляризации.

Составитель задания к. ф.-м. н., доцент С. Д. Животов